

INFORME PROYECTO FINAL

Carlos Enrique Alvarez Morales, Johan Sebastián Cuan Ramírez, Joan Nicolas Ávila Lache, Juan Sebastián Fonseca Parra

Facultad De Ingeniería

PLANTEAMIENTO DEL PROBLEMA

La educación superior en Colombia enfrenta constantes cambios en su composición estudiantil, influenciados por factores demográficos, socioeconómicos y de preferencia académica.

Comprender cómo se caracterizan los estudiantes matriculados en las Instituciones de Educación Superior (IES) permite identificar patrones relevantes para la planeación educativa, la formulación de políticas públicas y la toma de decisiones institucionales.

En particular, la ciudad de Bogotá, al concentrar una de las mayores ofertas de programas de educación superior del país, resulta un caso de estudio relevante para analizar cómo se distribuyen los estudiantes según variables demográficas (sexo) y académicas (nivel de formación, área de conocimiento). Sin embargo, esta información suele encontrarse dispersa o sin procesar en las bases de datos oficiales, lo que dificulta su interpretación directa.

Este proyecto busca abordar dicha necesidad mediante el procesamiento, limpieza y análisis de los datos de matrícula reportados para Bogotá durante el año 2023, con el fin de generar una caracterización clara y visualmente comprensible de la población estudiantil.

Pregunta principal de investigación

¿Cómo se caracterizan los estudiantes matriculados en las Instituciones de Educación Superior (IES) en la ciudad de Bogotá durante el año 2023, según sus características demográficas y académicas?

Preguntas secundarias

1. ¿Cuántos estudiantes se matricularon en los diferentes niveles de formación en Bogotá en el 2023?
2. ¿Cómo se distribuyen los estudiantes matriculados según el sexo en Bogotá en el 2023?
3. ¿Qué relación existe entre el área de conocimiento y el nivel de formación de los estudiantes matriculados en Bogotá durante el 2023?

Objetivo General

Caracterizar a los estudiantes matriculados en las Instituciones de Educación Superior de Bogotá durante el año 2023, a partir del análisis de variables demográficas y académicas, mediante el procesamiento estadístico y la visualización de datos oficiales de matrícula.

Objetivos específicos

- Obtener y depurar la base de datos de matrícula de educación superior correspondiente a Bogotá y al año 2023.
- Describir la distribución de los estudiantes según nivel de formación.
- Analizar la distribución de los estudiantes según sexo.
- Explorar la relación entre área de conocimiento y nivel de formación.
- Generar conclusiones y recomendaciones a partir de los hallazgos obtenidos.

BÚSQUEDA Y OBTENCIÓN DE DATOS

```
[16] ✓ 0 s
import os
os.listdir("/content")

[ '.config',
  'articles-421541_recurso.xlsx',
  '.ipynb_checkpoints',
  'sample_data' ]

[23] ✓ 21 s
df = pd.read_excel(NOMBRE ARCHIVO, sheet_name=HOJA, engine="openpyxl")
print(f"Filas originales: {len(df):,}")
df.head()

Filas originales: 49,271
```

Los datos utilizados en este proyecto provienen del portal oficial del Sistema Nacional de Información de la Educación Superior (SNIES), del Ministerio de Educación Nacional de Colombia, específicamente de la sección de Bases Consolidadas disponible en:

<https://snies.mineducacion.gov.co/portal/ESTADISTICAS/Bases-consolidadas/>

Dentro de esta sección se descargó la base correspondiente a Matriculados Primer Curso — Año 2023, la cual contiene el registro de estudiantes que ingresaron por primera vez a un programa de educación superior durante dicho año, desagregado por institución, programa, nivel de formación, área de conocimiento, sexo, municipio y departamento de oferta, entre otras

variables.

Se seleccionó esta fuente por las siguientes razones:

- Oficialidad: el SNIES es la plataforma oficial del Ministerio de Educación Nacional para el reporte y consulta de estadísticas de educación superior en Colombia, lo que garantiza la confiabilidad de los datos.
- Cobertura nacional y desagregación geográfica: permite filtrar la información específicamente por municipio y departamento de oferta, en este caso Bogotá D.C.
- Nivel de detalle: incluye variables demográficas y académicas necesarias para responder la pregunta principal y las preguntas secundarias del proyecto.
- Disponibilidad pública: al ser una base consolidada de datos abiertos, es de libre acceso y reutilización, lo que favorece la transparencia y reproducibilidad del análisis.

Proceso de Obtención

El archivo fue descargado directamente desde el portal SNIES en formato Excel (.xlsx) y posteriormente cargado en el entorno de trabajo de Google Colab para su procesamiento.

Alcance temporal y geográfico

- Alcance geográfico: Bogotá D.C. (municipio y departamento de oferta del programa).
- Alcance temporal: año 2023.
- Alcance poblacional: estudiantes matriculados en primer curso en un programa de educación superior durante el año 2023.

COMPRENSIÓN DEL CONJUNTO DE DATOS Y DESCRIPCIÓN DE LAS VARIABLES

La base de datos corresponde al reporte de matriculados en primer curso para el año 2023, a nivel nacional, con una fila por cada combinación de institución, programa, municipio, sexo y demás variables reportadas. Para efectos de este proyecto, se filtraron los datos para conservar únicamente los registros correspondientes a Bogotá D.C.

VARIABLE	TIPO	DESCRIPCION
MUNICIPIO DE OFERTA DEL PROGRAMA	TEXTO	Municipio donde se ofrece el programa académico. Usada para filtrar los registros de Bogotá D.C.
DEPARTAMENTO DE OFERTA DEL PROGRAMA	TEXTO	Departamento donde se ofrece el programa académico.

AÑO	NUMERICO (INT)	Año en que se reporta la matrícula. Usada para filtrar el año 2023
NIVEL DE FORMACIÓN	TEXTO	Nivel académico del programa (ej. Técnico Profesional, Tecnológico, Universitario, Especialización, Maestría, Doctorado).
SEXO	TEXTO	Sexo reportado del estudiante matriculado (Masculino/Femenino).
ÁREA DE CONOCIMIENTO	TEXTO	Área disciplinar a la que pertenece el programa académico (ej. Ingeniería, Ciencias de la Salud, Ciencias Sociales, entre otras).
INSTITUCIÓN DE EDUCACIÓN SUPERIOR (IES)	TEXTO	Nombre de la institución donde el estudiante se matriculó.
MATRICULADOS PRIMER CURSO	NUMERICO (INT)	Número de estudiantes matriculados por primera vez, para cada combinación de las variables anteriores.

PROCESO COMPLETO DE LIMPIEZA Y PREPARACIÓN DE LOS DATOS

A continuación, se describe, paso a paso, el proceso de limpieza y preparación aplicado al conjunto de datos, siguiendo el mismo orden en que se ejecutó en el código.

Carga del archivo

El archivo [articles-421541_recurso.xlsx](#) fue cargado con **pandas.read_excel()**. Durante esta etapa se presentó un error de tipo **BadZipFile**, indicando que el archivo estaba corrupto o incompleto. Se solucionó verificando el tamaño del archivo (8.24 MB, consistente con el tamaño esperado) y volviendo a descargarlo/subirlo al entorno de Colab, tras lo cual la lectura se realizó correctamente con el motor **openpyxl**.

Eliminación de filas vacías

```
# Columnas de texto que necesitan normalización (nombres consistentes para agrupar/filtrar)
columnas_texto = [
    "MUNICIPIO DE OFERTA DEL PROGRAMA",
    "DEPARTAMENTO DE OFERTA DEL PROGRAMA",
    "NIVEL DE FORMACIÓN",
    "SEXO",
    "ÁREA DE CONOCIMIENTO",
    "INSTITUCIÓN DE EDUCACIÓN SUPERIOR (IES)",
]

# Creamos una versión "_LIMPIO" de cada columna, dejando la original intacta por si acaso
for col in columnas_texto:
    df[col + "_LIMPIO"] = df[col].apply(limpiar_texto)

# Convertimos la columna de matriculados a numérico (por si vino como texto)
# errors="coerce" convierte en NaN cualquier valor que no se pueda transformar a número
df["MATRICULADOS PRIMER CURSO"] = pd.to_numeric(df["MATRICULADOS PRIMER CURSO"], errors="coerce")

# Eliminamos filas donde no se pudo obtener un número válido de matriculados
df = df.dropna(subset=["MATRICULADOS PRIMER CURSO"])

# Vista rápida de las columnas limpias para verificar que la normalización funcionó bien
df[[c for c in df.columns if "_LIMPIO" in c]].head()
```

Se eliminaron las filas completamente vacías (**dropna(how="all")**), es decir, registros sin ningún dato en ninguna columna, generados probablemente por el proceso de exportación del archivo original. Esto se hizo de forma segura, ya que no elimina registros con información parcial, solo los totalmente vacíos.

Normalización de texto

```
def limpiar_texto(valor):
    """Normaliza texto: sin tildes, sin ñ, sin caracteres especiales, en MAYÚSCULAS."""

    # Si el valor es NaN (vacío), lo dejamos igual, no tiene sentido "limpiar" un vacío
    if pd.isna(valor):
        return valor

    texto = str(valor) # aseguramos que sea texto, por si viene como número u otro tipo

    # Descompone letras con tilde/diéresis/ñ en su letra base + el acento como caracter aparte
    # ej: "Á" -> "A" + acento ; "Ñ" -> "N" + tilde
    texto = una.normalize("NFKD", texto)

    # Eliminamos esos acentos ya separados, quedándonos solo con la letra base
    texto = "".join(c for c in texto if not una.combining(c))

    # Convertimos todo a mayúsculas para evitar duplicados por formato (ej: "Bogota" vs "BOGOTA")
    texto = texto.upper()

    # Eliminamos cualquier caracter que no sea letra, número o espacio (puntos, comas, símbolos, etc.)
    texto = re.sub(r"[^A-Z0-9\s]", " ", texto)

    # Colapsamos múltiples espacios en uno solo y quitamos espacios al inicio/final
    texto = re.sub(r"\s+", " ", texto).strip()

    return texto
```

Se diseñó una función personalizada **limpiar_texto()** para estandarizar todas las variables categóricas relevantes. Esta función:

- Elimina tildes, diéresis y la letra ñ (convertida a n), mediante normalización Unicode (NFKD).
- Convierte todo el texto a mayúsculas, para evitar duplicidad de categorías por diferencias de capitalización.
- Elimina caracteres especiales (puntos, comas, símbolos), dejando únicamente letras, números y espacios.
- Colapsa espacios múltiples y elimina espacios al inicio/final del texto.

Esta función se aplicó a las siguientes columnas, generando una versión adicional **_LIMPIO** de cada una de las variables

- MUNICIPIO DE OFERTA DEL PROGRAMA
- DEPARTAMENTO DE OFERTA DEL PROGRAMA
- NIVEL DE FORMACIÓN
- SEXO

- ÁREA DE CONOCIMIENTO
- INSTITUCIÓN DE EDUCACIÓN SUPERIOR (IES)

Conversión y depuración de la variable numérica

La columna MATRICULADOS PRIMER CURSO fue convertida explícitamente a tipo numérico mediante `pd.to_numeric(..., errors="coerce")`, lo cual transforma en valores nulos (NaN) cualquier dato que no pudiera interpretarse como número. Posteriormente, se eliminaron las filas con valores nulos en esta columna, ya que un registro sin número de matriculados no aporta información válida para el análisis cuantitativo.

Filtrado geográfico y temporal

Finalmente, se filtró el conjunto de datos para conservar únicamente los registros correspondientes a:

- Municipio de oferta: Bogotá D.C. (usando la columna normalizada `MUNICIPIO DE OFERTA DEL PROGRAMA_LIMPIO == "BOGOTA D C"`).
- Año: 2023 (`AÑO == 2023`).

El resultado de este filtrado se almacenó en un nuevo dataframe (`df_bog`), que constituye la base de trabajo para todo el análisis posterior. Se verificó el número de filas resultantes y el total de estudiantes matriculados como control de calidad del proceso.

ANÁLISIS EXPLORATORIO DE DATOS

Antes de realizar pruebas estadísticas formales, se exploró el conjunto de datos filtrado (`df_bog`) para comprender su estructura general, la magnitud de las cifras y posibles anomalías que pudieran afectar el análisis posterior.

Volumen general de datos

Se revisó el número de registros resultantes tras el filtrado por Bogotá D.C. y año 2023, así como el total agregado de estudiantes matriculados en primer curso, como primer indicador del tamaño de la población de estudio.

Distribución por nivel de formación

```
# Crear figura y ejes
fig, ax = plt.subplots(figsize=(12, 7))

# Crear el gráfico de barras apiladas
tabla_cruzada.plot(kind="bar", stacked=True, ax=ax, colormap="tab10")

# Configurar título y etiquetas de ejes
ax.set_title("Matriculados por Área de Conocimiento y Nivel de Formación - Bogotá 2023",
             fontsize=12, fontweight="bold")
ax.set_xlabel("Área de Conocimiento")
ax.set_ylabel("Número de Matriculados")


# Rotar etiquetas del eje X para mejorar legibilidad
plt.xticks(rotation=45, ha="right")

# Posicionar la leyenda fuera del área del gráfico (a la derecha)
ax.legend(title="Nivel de Formación", bbox_to_anchor=(1.02, 1), loc="upper left", fontsize=8)

# Ajustar márgenes y mostrar
plt.tight_layout()
plt.show()


from scipy.stats import chi2_contingency
```

```
NIVEL DE FORMACIÓN_LIMPIO
UNIVERSITARIO                166830.0
TECNOLOGICO                  119731.0
ESPECIALIZACION UNIVERSITARIA 55874.0
FORMACION TECNICA PROFESIONAL 31365.0
MAESTRIA                     21052.0
ESPECIALIZACION MEDICO QUIRURGICA 1135.0
DOCTORADO                    786.0
ESPECIALIZACION TECNOLÓGICA  270.0
ESPECIALIZACION TECNICO PROFESIONAL 40.0
Name: MATRICULADOS PRIMER CURSO, dtype: float64
```




El análisis exploratorio de la variable NIVEL DE FORMACIÓN_LIMPIO mostró que la matrícula se concentra principalmente en los niveles Tecnológico y Universitario, mientras que los niveles de posgrado (especializaciones, maestría, doctorado) representan una proporción considerablemente menor del total. Esto es consistente con la estructura habitual del sistema de educación superior colombiano, donde el pregrado concentra la mayoría de la matrícula de primer curso.

Distribución por sexo



La exploración de la variable SEXO_LIMPIO permitió identificar la proporción de estudiantes matriculados por cada categoría (femenino/masculino), sentando la base para responder la pregunta secundaria 2 mediante el gráfico circular correspondiente.

Distribución por área de conocimiento



Al explorar la variable `ÁREA DE CONOCIMIENTO_LIMPIO`, se identificó que áreas como Economía, Administración, Contaduría y afines e Ingeniería, Arquitectura, Urbanismo y afines agrupan la mayor cantidad de matriculados, mientras que áreas como Bellas Artes, Matemáticas y Ciencias Naturales y Economía Veterinaria y afines presentan una participación marginal.

Adicionalmente, se identificó una categoría reportada como "SIN INFORMACIÓN", que agrupa un volumen considerable de registros (el más alto entre todas las áreas), lo cual constituye un hallazgo relevante sobre la calidad del dato de origen más que sobre el fenómeno educativo en sí.

Relación entre variables

Cruzando `ÁREA DE CONOCIMIENTO_LIMPIO` y `NIVEL DE FORMACIÓN_LIMPIO` mediante una tabla de contingencia, se observó que la composición por nivel de formación no es homogénea entre áreas: algunas concentran fuertemente su matrícula en el nivel tecnológico, mientras otras muestran mayor peso en el nivel universitario, sugiriendo desde esta etapa exploratoria (y confirmado posteriormente con la prueba chi-cuadrado) una posible asociación entre ambas variables.

Hallazgos preliminares de calidad de datos durante el EDA

- La categoría "SIN INFORMACIÓN" en área de conocimiento sugiere registros con datos incompletos en el reporte original del SNIES, que deben mencionarse como limitación del estudio.

- No se identificaron valores negativos ni atípicos evidentes en la variable MATRICULADOS PRIMER CURSO tras la limpieza, lo que respalda la validez de las sumas y proporciones calculadas.

ANÁLISIS ESTADÍSTICO REALIZADO

Se calcularon frecuencias absolutas y relativas (porcentajes) para cada una de las variables categóricas de interés, agregando la variable MATRICULADOS PRIMER CURSO como medida de conteo:

- Distribución por nivel de formación: total y proporción de matriculados en cada nivel (técnico profesional, tecnológico, universitario, especialización, maestría, doctorado).
- Distribución por sexo: total y proporción de matriculados femeninos y masculinos.
- Distribución por área de conocimiento: total y proporción de matriculados en cada área disciplinar.

Estas medidas permiten responder directamente las preguntas secundarias 1 y 2 del proyecto.


Análisis de asociación entre variables categóricas

```
# Crear figura y mapa de calor
fig, ax = plt.subplots(figsize=(12, 7))
im = ax.imshow(tabla_cruzada.values, cmap="YlGnBu", aspect="auto")

# Configurar etiquetas de ejes
ax.set_xticks(range(len(tabla_cruzada.columns)))
ax.set_xticklabels(tabla_cruzada.columns, rotation=45, ha="right", fontsize=8)
ax.set_yticks(range(len(tabla_cruzada.index)))
ax.set_yticklabels(tabla_cruzada.index, fontsize=8)

# Escribir los valores dentro de las celdas (cambiando color de texto según contraste)
for i in range(tabla_cruzada.shape[0]):
    for j in range(tabla_cruzada.shape[1]):
        valor = tabla_cruzada.values[i, j]
        if valor > 0:
            ax.text(j, i, f"{valor:,.0f}", ha="center", va="center", fontsize=7,
                    color="black" if valor < tabla_cruzada.values.max() * 0.6 else "white")

# Título, barra de color y mostrar
ax.set_title("Relación Área de Conocimiento vs Nivel de Formación - Bogotá 2023",
             fontsize=12, fontweight="bold")
fig.colorbar(im, ax=ax, label="Número de Matriculados")
plt.tight_layout()
plt.show()
```



Para responder la pregunta secundaria 3 (relación entre área de conocimiento y nivel de formación), se construyó una tabla de contingencia cruzando ambas variables, con la suma de matriculados como valor de celda. Sobre esta tabla se aplicó una prueba de independencia Chi-cuadrado (χ^2).

- Hipótesis nula (H_0): el nivel de formación y el área de conocimiento son independientes (no hay relación entre ellos).
- Hipótesis alternativa (H_1): existe una asociación entre el nivel de formación y el área de conocimiento.
- Nivel de significancia: $\alpha = 0.05$.

ESTADISTICO	VALOR
Chi-cuadrado (χ^2)	172,658.93
Grados de libertad	64
Valor p	< 0.0000000001

Interpretación: dado que el valor p obtenido es considerablemente menor que el nivel de significancia establecido ($\alpha = 0.05$), se rechaza la hipótesis nula. Esto indica que existe una asociación estadísticamente significativa entre el área de conocimiento y el nivel de formación de los estudiantes matriculados en Bogotá durante 2023. En otras palabras, la distribución de los niveles de formación no es independiente del área de conocimiento: ciertas áreas tienden a

concentrarse en niveles específicos de formación (por ejemplo, predominio del nivel tecnológico en algunas áreas, mientras otras muestran mayor presencia de programas universitarios o de posgrado).

Es importante señalar que, dado el tamaño muy grande de la muestra (más de un millón de registros agregados), la prueba chi-cuadrado es altamente sensible y prácticamente cualquier diferencia entre categorías resultará estadísticamente significativa. Por ello, el valor p se complementa con el análisis visual de la tabla de contingencia (gráfico de barras apiladas), que permite dimensionar la magnitud práctica de estas diferencias, no solo su significancia estadística.

Justificación del enfoque estadístico

Se optó por pruebas y medidas propias de variables categóricas (frecuencias, proporciones, chi-cuadrado) en lugar de estadísticos como media o desviación estándar sobre variables cualitativas, ya que estos últimos no son interpretables en este contexto. La variable numérica (MATRICULADOS PRIMER CURSO) se usó exclusivamente como magnitud de conteo para ponderar las categorías, no como variable continua a analizar en sí misma.

HALLAZGOS DE PATRONES, RELACIONES E INSIGHTS

Antes de realizar pruebas estadísticas formales, se exploró el conjunto de datos filtrado (df_bog) para comprender su estructura general, la magnitud de las cifras y posibles anomalías que pudieran afectar el análisis posterior.

Volumen general de datos

Se revisó el número de registros resultantes tras el filtrado por Bogotá D.C. y año 2023, así como el total agregado de estudiantes matriculados en primer curso, como primer indicador del tamaño de la población de estudio.

Distribución por nivel de formación

El análisis exploratorio de la variable NIVEL DE FORMACIÓN_LIMPIO mostró que la matrícula se concentra principalmente en los niveles **Tecnológico** y **Universitario**, mientras que los niveles de posgrado (especializaciones, maestría, doctorado) representan una proporción considerablemente menor del total. Esto es consistente con la estructura habitual del sistema de educación superior colombiano, donde el pregrado concentra la mayoría de la matrícula de primer curso.

Distribución por sexo

La exploración de la variable SEXO_LIMPIO permitió identificar la proporción de estudiantes matriculados por cada categoría (femenino/masculino), sentando la base para responder la pregunta secundaria 2 mediante el gráfico circular correspondiente.

Distribución por área de conocimiento

Al explorar la variable `ÁREA DE CONOCIMIENTO_LIMPIO`, se identificó que áreas como Economía, Administración, Contaduría y afines e Ingeniería, Arquitectura, Urbanismo y afines agrupan la mayor cantidad de matriculados, mientras que áreas como Bellas Artes, Matemáticas y Ciencias Naturales y Economía Veterinaria y afines presentan una participación marginal.

Adicionalmente, se identificó una categoría reportada como **"SIN INFORMACIÓN"**, que agrupa un volumen considerable de registros (el más alto entre todas las áreas), lo cual constituye un hallazgo relevante sobre la calidad del dato de origen más que sobre el fenómeno educativo en sí.

Relación entre variables

Cruzando `ÁREA DE CONOCIMIENTO_LIMPIO` y `NIVEL DE FORMACIÓN_LIMPIO` mediante una tabla de contingencia, se observó que la composición por nivel de formación no es homogénea entre áreas: algunas concentran fuertemente su matrícula en el nivel tecnológico, mientras otras muestran mayor peso en el nivel universitario, sugiriendo desde esta etapa exploratoria (y confirmado posteriormente con la prueba chi-cuadrado) una posible asociación entre ambas variables.

Hallazgos preliminares de calidad de datos durante el EDA

- La categoría "SIN INFORMACIÓN" en área de conocimiento sugiere registros con datos incompletos en el reporte original del SNIES, que deben mencionarse como limitación del estudio.
- No se identificaron valores negativos ni atípicos evidentes en la variable `MATRICULADOS PRIMER CURSO` tras la limpieza, lo que respalda la validez de las sumas y proporciones calculadas.

SELECCIÓN DEL MODELO Y JUSTIFICACIÓN DE SU ELECCIÓN

La variable objetivo del análisis, `MATRICULADOS PRIMER CURSO`, es una **variable numérica de conteo** (representa cantidad de estudiantes). Esto define el problema como una tarea de **regresión** (predicción de un valor numérico continuo), y no de clasificación, ya que no se busca predecir una categoría sino una cantidad.

Variables predictoras consideradas

Para explicar el comportamiento de la variable objetivo se seleccionaron variables categóricas asociadas a las características del programa y la institución:

- Nivel de formación
- Sexo

- Área de conocimiento
- Semestre
- Sector de la institución de educación superior
- Modalidad

Estas variables fueron elegidas por ser las disponibles en la base de datos con mayor relación conceptual con el volumen de matrícula, y por haber sido previamente depuradas y estandarizadas durante el proceso de limpieza.

Justificación del modelo: Random Forest Regressor

Se seleccionó el algoritmo **Random Forest Regressor** por las siguientes razones:

1. **Compatibilidad con variables categóricas múltiples:** el conjunto de predictores es en su totalidad categórico (nivel de formación, sexo, área, semestre, sector, modalidad). Random Forest maneja bien este tipo de variables una vez codificadas, sin requerir supuestos sobre la distribución de los datos.
2. **No exige relaciones lineales:** a diferencia de una regresión lineal simple, Random Forest puede capturar relaciones complejas y no lineales entre las variables predictoras y la cantidad de matriculados, lo cual es esperable en datos administrativos como estos (por ejemplo, la relación entre área de conocimiento y nivel de formación ya demostrada como no independiente mediante la prueba chi-cuadrado).
3. **Robustez frente a valores atípicos y ruido:** al ser un modelo basado en el promedio de múltiples árboles de decisión, es menos sensible a valores extremos que otros modelos de regresión, lo cual resulta útil dado que ciertas combinaciones de categorías (ej. algunas IES o áreas específicas) presentan volúmenes de matrícula muy dispares entre sí.
4. **Facilidad de interpretación relativa:** aunque no es tan interpretable como una regresión lineal, permite obtener la **importancia de cada variable** en la predicción, lo cual aporta valor analítico adicional para responder la pregunta principal del proyecto (qué características se asocian más con el volumen de matrícula).
5. **Buen desempeño con conjuntos de datos de tamaño moderado:** con 12,056 registros, Random Forest es una opción adecuada, evitando tanto el sobreajuste de modelos muy complejos (como redes neuronales, que requieren más datos) como la simplicidad excesiva de un modelo lineal.

Alternativas descartadas

- **Regresión lineal múltiple:** descartada por la naturaleza categórica de todas las variables predictoras y la probable existencia de relaciones no lineales entre ellas.

- **Árbol de decisión simple:** descartado por su mayor tendencia al sobreajuste en comparación con un ensamble como Random Forest.
- **Modelos de clasificación:** no aplican, ya que la variable objetivo es numérica y no categórica.

APLICACIÓN DEL MODELO

Para complementar el análisis de los datos de educación superior, se aplicó un modelo de aprendizaje automático de random forest regressor, debido a que la variable que se iba a predecir, **Matriculados primer curso**, es una variable numérica

El modelo se aplicó sobre los datos correspondientes a **bogotá durante 2023**. Para este proceso se trabajó con la información previamente limpiada y organizada. La limpieza incluyó la normalización de variables de texto, eliminando tildes, caracteres especiales y diferencias en la escritura de los datos. Posteriormente, se realizó el filtro de los registros correspondientes a Bogotá y al año 2023

El conjunto utilizado para el análisis contiene **12.056 registros**. La variable objetivo fue la cantidad de estudiantes matriculados en primer curso

Para realizar las predicciones se utilizaron variables relacionadas con las características de los programas e instituciones como

- Nivel de formación
- Sexo
- Área de conocimiento
- Semestre
- Sector de la institución de educación superior.
- Modalidad

Los datos fueron divididos en un conjunto de entrenamiento y otro de prueba. El conjunto de entrenamiento permitió que el modelo aprendiera los patrones presentes en los datos, mientras que el conjunto de prueba permitió comprobar qué tan bien podía realizar predicciones sobre datos que no había utilizado durante el entrenamiento

Finalmente, el modelo generó una predicción de la cantidad de estudiantes matriculados para cada registro del conjunto de prueba

EVALUACIÓN DEL MODELO

Para evaluar el desempeño del modelo se utilizaron tres métricas principales: **MAE**, **RMSE** y **R²**

Los resultados obtenidos fueron

Métrica	Resultado
MAE	30,74
RMSE	123,17
R ²	0,179

MAE – Error absoluto medio

El **MAE fue de 30,74**. Este resultado significa que en promedio, las predicciones realizadas por el modelo presentan una diferencia aproximada de **31 estudiantes** frente al valor real

Esta métrica permite conocer de manera sencilla qué tan alejadas están, en promedio, las predicciones de los valores reales

RMSE – Raíz del error cuadrático medio

El **RMSE fue de 123,17**. Este valor es considerablemente mayor que el MAE porque esta métrica da mayor importancia a los errores grandes

Esto puede estar relacionado con que existen registros con cantidades de estudiantes matriculados mucho mayores que la mayoría de los datos. Por lo tanto, algunos errores grandes tienen un impacto importante en el resultado final

R² – Coeficiente de determinación

El modelo obtuvo un **R² de 0,179**, lo que significa que aproximadamente el **17,9 % de la variación** en la cantidad de estudiantes matriculados puede ser explicada por las variables utilizadas en el modelo

Por lo tanto, aunque el modelo logra encontrar algunos patrones en los datos, su capacidad para explicar y predecir completamente la cantidad de matriculados es limitada

Interpretación de resultados

```
from sklearn.model_selection import train_test_split
from sklearn.ensemble import RandomForestRegressor
from sklearn.preprocessing import OrdinalEncoder
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import numpy as np

# --- 0. Limpieza rápida de las columnas que faltaban normalizar ---
df_bog["SECTOR IES_LIMPIO"] = df_bog["SECTOR IES"].apply(limpiar_texto)
df_bog["MODALIDAD_LIMPIO"] = df_bog["MODALIDAD"].apply(limpiar_texto)
|
# --- 1. Selección de variables predictoras y variable objetivo ---
columnas_predictoras = [
    "NIVEL DE FORMACIÓN_LIMPIO",
    "SEXO_LIMPIO",
    "ÁREA DE CONOCIMIENTO_LIMPIO",
    "SEMESTRE",
    "SECTOR IES_LIMPIO",
    "MODALIDAD_LIMPIO",
]
variable_objetivo = "MATRICULADOS PRIMER CURSO"

# Dataframe de trabajo, solo con las columnas necesarias y sin nulos
df_modelo = df_bog[columnas_predictoras + [variable_objetivo]].dropna()
print(f"Registros disponibles para el modelo: {len(df_modelo):,}")

# --- 2. Codificación de variables categóricas a números ---
# SEMESTRE ya es numérica, así que la excluimos de la codificación ordinal
columnas_categoricas = [
    "NIVEL DE FORMACIÓN_LIMPIO",
    "SEXO_LIMPIO",
    "ÁREA DE CONOCIMIENTO_LIMPIO",
    "SECTOR IES_LIMPIO",
    "MODALIDAD_LIMPIO",
]

encoder = OrdinalEncoder()
X = df_modelo[columnas_predictoras].copy()
X[columnas_categoricas] = encoder.fit_transform(X[columnas_categoricas])
y = df_modelo[variable_objetivo]
```

```

# --- 3. División en entrenamiento (80%) y prueba (20%) ---
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
print(f"Entrenamiento: {len(X_train):,} | Prueba: {len(X_test):,}")

# --- 4. Entrenamiento del modelo ---
modelo_rf = RandomForestRegressor(n_estimators=200, random_state=42, n_jobs=-1)
modelo_rf.fit(X_train, y_train)

# --- 5. Predicción y métricas de evaluación ---
y_pred = modelo_rf.predict(X_test)
mae = mean_absolute_error(y_test, y_pred)
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
r2 = r2_score(y_test, y_pred)

print(f"MAE: {mae:,.2f}")
print(f"RMSE: {rmse:,.2f}")
print(f"R²: {r2:,.3f}")

# --- 6. Gráfico: valores reales vs. valores predichos ---
fig, ax = plt.subplots(figsize=(8, 8))
ax.scatter(y_test, y_pred, alpha=0.4, color="#2E86AB", s=15)



limite_max = max(y_test.max(), y_pred.max())
ax.plot([0, limite_max], [0, limite_max], "r--", linewidth=1.5, label="Predicción ideal")

ax.set_title("Valores Reales vs. Valores Predichos - Random Forest", fontsize=13, fontweight="bold")
ax.set_xlabel("Matriculados reales")
ax.set_ylabel("Matriculados predichos")
ax.legend()
plt.tight_layout()
plt.show()

# --- 7. Importancia de variables ---
importancias = pd.Series(modelo_rf.feature_importances_, index=columnas_predictoras).sort_values(ascending=False)

fig, ax = plt.subplots(figsize=(8, 5))
importancias.plot(kind="barh", ax=ax, color="#2E86AB")
ax.set_title("Importancia de Variables - Random Forest", fontsize=12, fontweight="bold")
ax.set_xlabel("Importancia")
ax.invert_yaxis()
plt.tight_layout()
plt.show()

```



Los resultados obtenidos muestran que el modelo de Random Forest logró identificar algunas relaciones entre las características de los programas y la cantidad de estudiantes matriculados en primer curso.

Sin embargo, el resultado del **R^2 de 0,179** indica que todavía existe una gran parte de la variación que no puede ser explicada por las variables incluidas en el modelo. Esto significa que probablemente existen otros factores que pueden influir en la cantidad de estudiantes matriculados

Además, la diferencia entre el **MAE de 30,74** y el **RMSE de 123,17** indica que existen algunos casos con errores de predicción bastante grandes. Esto es importante porque la cantidad de estudiantes no es igual en todos los programas y existen registros con valores de matrícula mucho más altos

También se utilizó una gráfica de **valores reales frente a valores predichos**. En esta gráfica, la línea punteada representa la situación ideal en la que el valor predicho coincide exactamente con el valor real

Al observar la gráfica, varios puntos se encuentran alejados de esta línea, especialmente en algunos valores altos de matriculados. Esto permite visualizar que el modelo presenta dificultades para realizar predicciones precisas en determinados casos

En general, los resultados muestran que el modelo puede servir como una herramienta para identificar ciertos patrones, pero **no debe considerarse como un modelo de predicción completamente preciso** con las variables utilizadas

CONCLUSIONES

La aplicación del modelo de Random Forest permitió complementar el análisis descriptivo de los estudiantes matriculados en primer curso en Bogotá durante 2023 mediante una herramienta de aprendizaje automático

El modelo permitió utilizar diferentes características de los programas e instituciones para realizar predicciones sobre la cantidad de estudiantes matriculados. Sin embargo, los resultados obtenidos muestran que su capacidad predictiva es limitada

El MAE de 30,74 indica que las predicciones presentan, en promedio, una diferencia de aproximadamente 31 estudiantes respecto a los valores reales. Por otra parte, el RMSE de 123,17 muestra la presencia de algunos errores de mayor magnitud. Finalmente, el R^2 de 0,179 evidencia que el modelo explica una proporción relativamente baja de la variación de los datos

Por lo anterior, se concluye que el modelo permite identificar algunos patrones relacionados con la matrícula, pero es necesario considerar otros factores para conseguir predicciones más precisas

Como posible mejora para futuros análisis, se podrían incorporar más variables relacionadas con las instituciones, los programas académicos y las características de los estudiantes, además de comparar diferentes modelos de aprendizaje automático para determinar cuál presenta un mejor desempeño

REFERENCIAS Y BIBLIOGRAFIA

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.

<https://doi.org/10.1023/A:1010933404324>

Ministerio de Educación Nacional. (2023). *Matriculados primer curso 2023* [Conjunto de datos]. Sistema Nacional de Información de la Educación Superior (SNIES).

<https://snies.mineducacion.gov.co/portal/ESTADISTICAS/Bases-consolidadas/>