

SNIES BOGOTA 2023

Caracterización de estudiantes matriculados en Instituciones de Educación Superior de Bogotá

Informe final · Limpieza, análisis estadístico y modelo predictivo

49.271

Registros iniciales

12.056

Registros Bogotá 2022

3

Preguntas de análisis

Carlos Enrique Álvarez Morales · Juan Sebastián Fonseca Parra

Joan Nicolás Ávila Lache · Johan Sebastián Cuan Ramírez



Agenda

1

Planteamiento del problema y objetivo

2

Búsqueda y obtención de los datos

3

Comprensión del dataset y variables

4

Limpieza y preparación de los datos

5

Análisis exploratorio (EDA)

6

Análisis estadístico

7


Selección y aplicación del modelo

8

Evaluación del modelo

9

Conclusiones y recomendaciones



01

Planteamiento del problema y objetivo

PROBLEMA

La educación superior en Colombia presenta cambios en su composición estudiantil, por lo que analizar sus características permite identificar patrones útiles para la planeación educativa. Este proyecto busca caracterizar a los estudiantes matriculados en Bogotá durante 2023 según variables demográficas y académicas, mediante la limpieza, procesamiento y visualización de datos.

PREGUNTA PRINCIPAL

¿Cómo se caracterizan los estudiantes matriculados en IES en Bogotá durante 2023 según sus características académicas y demográficas?

OBJETIVO DEL PROYECTO

Caracterizar a los estudiantes matriculados en las Instituciones de Educación Superior de Bogotá durante el año 2023, a partir del análisis de variables demográficas y académicas, mediante el procesamiento estadístico y la visualización de datos oficiales de matrícula.

PREGUNTAS DE APOYO

1

Cuántos estudiantes se matricularon en cada nivel de formación.

2

Cómo se distribuyen los estudiantes según el sexo.

3

Qué relación existe entre el área de conocimiento y el nivel de formación.



02

Búsqueda y obtención de los datos

FUENTE

Sistema Nacional de Información de la Educación Superior (SNIES), Ministerio de Educación Nacional — base entregada en formato Excel.

JUSTIFICACIÓN

- Fuente oficial del gobierno colombiano sobre matrícula en educación superior.
- Cobertura nacional, lo que permite filtrar específicamente Bogotá 2022.
- Nivel de detalle suficiente para cruzar variables académicas y demográficas.

PROCESAMIENTO

1

Excel SNIES (49271 registros)

2

Carga en Google Colab

3

Limpieza y normalización (Python / Pandas)

4

Filtro Bogotá + 2023 (12056 registros)

5

Análisis, prueba estadística y modelo



03

Comprensión del dataset y variables

Variable	Tipo	Función en el análisis
DEPARTAMENTO DE OFERTA	Texto	Permite seleccionar Bogotá.
AÑO	Numérica (año)	Delimita el periodo 2023.
NIVEL DE FORMACIÓN	Texto	Permite comparar niveles académicos.
SEXO	Texto	Permite analizar la distribución demográfica.
ÁREA DE CONOCIMIENTO	Texto	Permite estudiar relaciones académicas.
MATRICULADOS	Numérica (conteo)	Variable principal para cuantificar estudiantes.
CARRERA	Texto	Variables complementarias para ampliar el análisis.



04

Limpieza y preparación de los datos



Se identificaron los encabezados y tipos de datos antes de modificar la información.




Se comprobó la existencia de valores faltantes: no se encontraron valores vacíos en la base revisada.




Se creó una copia de seguridad de la base original antes de aplicar transformaciones.

Esto garantizó que ninguna transformación posterior alterara información sin control ni posibilidad de reversión.




EDA — Nivel de formación




LECTURA DEL GRÁFICO

Al agrupar los datos por nivel de formación y sumar los matriculados, se observa que la matrícula en Bogotá durante 2023 se concentra principalmente en los niveles Tecnológico y Universitario, que en conjunto agrupan la gran mayoría de los estudiantes. Le siguen, con una participación mucho menor, la Formación Técnica Profesional y la Especialización Universitaria. Los niveles de posgrado Maestría, Doctorado, Especialización Técnico Profesional y Especialización Tecnológica representan una proporción marginal del total, lo cual es consistente con la estructura habitual del sistema de educación superior colombiano, donde el pregrado concentra la mayoría de la matrícula de primer curso.




EDA — Sexo



LECTURA DEL GRÁFICO


Al agrupar los datos por sexo y sumar los matriculados, se observa que la distribución entre mujeres y hombres matriculados en Bogotá durante 2023 presenta una mayor proporción de (mujeres/hombres), aproximadamente 51.4% frente a 48.6%. Esto permite caracterizar la composición demográfica de la población estudiantil de primer curso en la ciudad y responde directamente a la pregunta secundaria 2 del proyecto.



05


EDA — Área de conocimiento × Nivel de formación

Tabla cruzada AREA_CONOCIMIENTO × NIVEL_FORMACION (suma de MATRICULADOS). Insertar aquí el mapa de calor (Seaborn) generado en Colab.



LECTURA DEL GRÁFICO

El mapa de calor permite identificar qué combinaciones de área de conocimiento y nivel de formación concentran más estudiantes matriculados en Bogotá durante 2023. La celda con mayor volumen corresponde a "SIN INFORMACIÓN" × "TECNOLÓGICO", con 84,399 matriculados, lo cual constituye más un hallazgo de calidad del dato de origen que un patrón académico real. Excluyendo esa categoría, las combinaciones más fuertes son "Economía, Administración y Contaduría" × "Universitario" (45,075) y "Economía, Administración y Contaduría" × "Especialización Universitaria" (17,997), seguidas de "Ingeniería, Arquitectura y Urbanismo" × "Universitario" (35,428) y "Ingeniería, Arquitectura y Urbanismo" × "Formación Técnica Profesional" (11,902). En contraste, los niveles de posgrado (Doctorado, Especialización Técnico Profesional y Especialización Tecnológica) presentan valores marginales en prácticamente todas las áreas de conocimiento, lo que confirma la baja participación de los posgrados en la matrícula de primer curso de la ciudad.



06

Análisis estadístico

Prueba Chi-cuadrado de independencia · Tabla de contingencia: ÁREA DE CONOCIMIENTO × NIVEL DE FORMACIÓN

H0: el área de conocimiento y el nivel de formación son independientes.

H1: existe una relación de dependencia entre ambas variables.

RESULTADO DE LA PRUEBA

χ^2

172,658.93

GRADOS LIBERTAD

64

P-VALOR

<0.0000000001

CONCLUSION

Se rechaza H0

```
from scipy.stats import chi2_contingency

chi2, p_valor, gl, esperado = chi2_contingency(tabla_cruzada)
print(f"Chi-cuadrado: {chi2:,.2f}")
print(f"Valor p: {p_valor:.10f}")
print(f"Grados de libertad: {gl}")
```

```
Chi-cuadrado: 172,658.93
Valor p: 0.0000000000
Grados de libertad: 64
```



07

Hallazgos y patrones (insights)

1

Concentración por nivel

Los niveles Tecnológico y Universitario concentran la gran mayoría de la matrícula de primer curso en Bogotá, mientras que los posgrados (especialización, maestría, doctorado) representan una proporción marginal. Esto sugiere que la oferta académica de la ciudad sigue orientada principalmente a la formación de pregrado, con espacio de crecimiento en programas de posgrado.

2

Distribución por sexo

La matrícula muestra una distribución equilibrada / con mayor participación de mujeres u hombres] entre sexos, con 48.6% hombres frente a 51.4% mujeres, lo que refleja un acceso relativamente equitativo a la educación superior en la ciudad

3

Relación área-nivel

La prueba Chi-cuadrado ($\chi^2=172,658.93$; $p<0.0000000001$) confirma que el área de conocimiento y el nivel de formación están relacionados de forma estadísticamente significativa, respaldando lo observado en el mapa de calor: áreas como Economía, Administración y Contaduría, e Ingeniería, Arquitectura y Urbanismo concentran su matrícula principalmente en el nivel Universitario, mientras que los posgrados tienen una presencia marginal en todas las áreas.

APLICACIÓN DEL MODELO

Random Forest Regressor

- Se utilizó un modelo de Random Forest para predecir la cantidad de estudiantes matriculados en primer curso.
- Datos correspondientes a Bogotá, 2023.
- Se utilizaron 12.056 registros.
- Variables utilizadas:
 - Nivel de formación
 - Sexo
 - Área de conocimiento
 - Semestre
 - Sector IES
 - Modalidad
- División de datos: 80 % entrenamiento / 20 % prueba.

```
modelo.fit(X_train, y_train)
y_pred = modelo.predict(X_test)
```

¿Qué hace?

Entrena el modelo con los datos de entrenamiento y posteriormente genera las predicciones sobre los datos de prueba.

EVALUACIÓN DEL MODELO

Métrica	Resultado
MAE	30,74
RMSE	123,17
R ²	0,179

¿Qué significa?

- MAE: el error promedio fue de aproximadamente 31 estudiantes.
- RMSE: muestra que existen algunos errores bastante altos.
- R²: el modelo explica aproximadamente el 17,9 % de la variabilidad de los datos.


```
mae = mean_absolute_error(y_test, y_pred)
rmse = mean_squared_error(y_test, y_pred) ** 0.5
r2 = r2_score(y_test, y_pred)
```

Este código sirve para evaluar qué tan buenas son las predicciones del modelo. Compara los valores reales (`y_test`) con los valores que predijo el modelo (`y_pred`) y calcula tres métricas:

MAE, RMSE y R².

- MAE: calcula cuánto se equivoca el modelo en promedio.
- RMSE: mide el error y da mayor importancia a los errores grandes.
- R²: indica qué tanto logra explicar el modelo la variación de los datos.

INTERPRETACIÓN DE RESULTADOS



La gráfica compara los valores reales de estudiantes matriculados con los valores predichos por el modelo. Los puntos cercanos a la línea representan predicciones más acertadas, mientras que los puntos alejados muestran mayores errores.

Principal resultado:

El modelo identifica algunos patrones, pero presenta dificultades para predecir con precisión los valores más altos de matriculados.

Esta gráfica nos permite ver qué tan cerca están las predicciones del modelo de los valores reales. Mientras más cerca estén los puntos de la línea punteada, mejor es la predicción. En nuestra gráfica vemos varios puntos alejados de la línea, especialmente en valores altos, lo que muestra que el modelo tiene dificultades para predecir algunos casos.



11

Conclusiones y recomendaciones

CONCLUSIONES

- El proyecto transformó una base extensa en información útil mediante limpieza, filtrado, agrupación y visualización.
- La prueba estadística y el modelo de regresión permitieron ir más allá de lo descriptivo, cuantificando relaciones entre variables.
- [Agregar conclusión específica del resultado del modelo una vez tengan los valores reales].

RECOMENDACIONES

- Usar la caracterización para apoyar la planeación de oferta académica en Bogotá.
- Priorizar áreas y niveles con menor matrícula relativa si se busca ampliar cobertura.
- Ampliar el estudio a otros años y ciudades para validar si los patrones se mantienen.
- Profundizar en metodología y semestre en un próximo corte.



Referencias



Sistema Nacional de Información de la Educación Superior (SNIES) — Ministerio de Educación Nacional de Colombia.

<https://snies.mineduacion.gov.co>



Repositorio de GitHub del proyecto.

<https://pandas.pydata.org>



Cuaderno de Google Colab.

<https://numpy.org>